

BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
PHÂN HIỆU TRƯỜNG ĐẠI HỌC THỦY LỢI
BỘ MÔN CÔNG NGHỆ THÔNG TIN



MÔN HỌC: Học Máy

TÊN ĐỀ TÀI: Thăm họa toàn cầu

Giảng viên:	Vũ Thị Hạnh
Sinh viên thực hiện:	Nguyễn Anh Khoa Nguyễn Hoàng Tuấn Anh Trần Minh Hiếu
Mã sinh viên:	2351267269 2351267255 2351267266
Lớp:	S26-65TTNT

TP. Hồ Chí Minh, ngày ... tháng ... năm 2025

This image shows a full page of white paper with horizontal dotted lines, typical of primary school writing paper. The lines are evenly spaced and run across the width of the page. There are no margins, text, or other markings on the paper.

Chữ ký của giảng viên

LỜI CẢM ƠN

Lời đầu tiên, nhóm em xin gửi lời cảm ơn chân thành đến Khoa Công nghệ Thông tin – Phân hiệu Trường Đại học Thủy Lợi đã đưa môn học Xử lý ảnh số vào chương trình đào tạo. Đây là một môn học có tính ứng dụng cao, giúp em hiểu rõ hơn về các kỹ thuật xử lý ảnh cũng như nền tảng toán học và thuật toán phía sau các hệ thống xử lý ảnh trong thực tế.

Trong quá trình học tập môn học này, em đã nhận được sự quan tâm và hướng dẫn tận tình của các thầy, cô trong bộ môn Công nghệ Thông tin. Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc đến giảng viên trực tiếp giảng dạy môn học là cô: Hoàng Thị Kiều Anh, người đã cung cấp cho em những kiến thức nền tảng quan trọng, đồng thời định hướng rõ ràng trong quá trình thực hiện các bài tập thực hành và xây dựng ứng dụng xử lý ảnh.

Thông qua việc thực hiện bài báo cáo này, em có cơ hội vận dụng các kiến thức đã học để xây dựng một ứng dụng xử lý ảnh số, trong đó các thuật toán được cài đặt thủ công nhằm giúp em hiểu rõ hơn bản chất của từng phương pháp xử lý ảnh trong cả miền không gian và miền tần số. Đây là một trải nghiệm học tập có ý nghĩa, giúp em củng cố kiến thức lý thuyết và nâng cao kỹ năng lập trình.

Nhóm xin chân thành cảm ơn!

Mục Lục

Contents

CHƯƠNG 1. GIỚI THIỆU CHUNG.....	7
1.1. Bối cảnh và động cơ nghiên cứu.....	7
• Thảm họa thiên nhiên và nhân tạo ngày càng gia tăng	7
• Tác động lớn đến:.....	7
○ Con người.....	7
○ Kinh tế.....	7
○ Thời gian phục hồi xã hội	7
• Vai trò của phân tích dữ liệu & học máy trong dự báo và hỗ trợ ra quyết định	7
.....	7
1.2. Mục tiêu nghiên cứu.....	7
Trong báo cáo này, nhóm/tác giả tập trung giải quyết 3 bài toán dự đoán chính:	7
1. Dự đoán thiệt hại về người.....	7
2. Dự đoán thời gian phục hồi sau thảm họa.....	7
3. Dự đoán mức độ nghiêm trọng của thảm họa	7
.....	7
1.3. Phạm vi và dữ liệu sử dụng.....	7
• Nguồn dữ liệu: Global Disaster Response Dataset (2018–2024)	7
• Đối tượng: các sự kiện thảm họa trên phạm vi toàn cầu.....	7
• Công cụ:	7
○ Python	7
○ Pandas, NumPy	7
○ Scikit-learn	7

○ Streamlit (triển khai ứng dụng)	Error! Bookmark not defined.
CHƯƠNG 2. TỔNG QUAN DỮ LIỆU VÀ TIỀN XỬ LÝ	8
2.1 Các nhóm đặc trưng chính trong bộ dữ liệu.....	8
2.2. Mô tả các biến quan trọng.....	9
CHƯƠNG 3. BÀI TOÁN 1 – DỰ ĐOÁN THIẾT HẠI VỀ NGƯỜI.....	11
CHƯƠNG 4. BÀI TOÁN 2 – DỰ ĐOÁN THỜI GIAN PHỤC HỒI	11
4.1. Mô tả bài toán.....	11
4.1.1. Loại bài toán.....	11
4.1.2. Biến mục tiêu	12
4.1.3. Ý nghĩa trong quản lý rủi ro thảm họa	12
4.2. Phân tích EDA (Exploratory Data Analysis)	12
4.2.1. Quan hệ giữa recovery_days và severity_index	13
4.2.3. Quan hệ giữa recovery_days và aid_amount_usd.....	15
4.2.4. Quan hệ giữa recovery_days và disaster_type.....	15
4.2.5. Quan hệ giữa recovery_days và country	16
4.5. Triển khai ứng dụng dự đoán	17
4.5.1. Mô tả web app Streamlit	17
4.5.2. Giao diện nhập feature	18
4.5.3. Kết quả dự đoán	18
4.6. Kết luận bài toán 2	19
4.6.1. Hiệu quả mô hình	19
4.6.2. Tính ứng dụng thực tế	19
CHƯƠNG 5. BÀI TOÁN 3 – DỰ ĐOÁN MỨC ĐỘ THẢM HỌA	19
5.1 GIỚI THIỆU ĐỀ TÀI	19
5.1.1 Đặt vấn đề	19
5.1.2. Mục tiêu đề án.....	19

5.2 CƠ SỞ DỮ LIỆU VÀ TIỀN XỬ LÝ	20
5.2.1. Nguồn dữ liệu.....	20
5.2.2. Quy trình xử lý dữ liệu (Data Preprocessing)	20
5.3 PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)	21
5.3.1. Phân bố các loại hình thiên tai	21
5.3.2. Phân tích mức độ nghiêm trọng (Severity Level).....	23
5.3.3. <i>Tương quan giữa các đặc trưng Biểu đồ phân tích mức độ ảnh hưởng của các đặc trưng (Feature Importance) từ mô hình Random Forest cho thấy:</i>	24
5.4 XÂY DỰNG VÀ HUẤN LUYỆN MÔ HÌNH.....	24
5.4.1. Thiết lập quy trình huấn luyện (Pipeline)	24
5.4.2. Các thuật toán thử nghiệm	25
5.4.3. Tối ưu hóa tham số (Hyperparameter Tuning)	25
5.4.4. Kết quả đánh giá.....	25
5.5 XÂY DỰNG ỨNG DỤNG DỰ BÁO	27
5.5.1. Thiết kế giao diện.....	27
5.5.2. Chức năng hoạt động	28
5.5.3 Thống kê số lần thảm họa cùng thời gian đó ở 1 nước của quá khứ.....	29
5.5.4 KẾT LUẬN.....	29
6.6. TỔNG KẾT & HƯỚNG PHÁT TRIỂN.....	30
6.1. Tổng kết kết quả đạt được.....	30
6.2. Hạn chế của nghiên cứu	32
6.2.1. Dữ liệu còn nhiều	32
6.2.2. Thiếu các yếu tố kinh tế – xã hội chuyên sâu	32
6.3. Hướng phát triển	32
6.3.1. Bổ sung dữ liệu thời gian thực	32
6.3.2. Tích hợp bản đồ và dashboard trực quan	32

6.3.3. Ứng dụng trong hệ thống cảnh báo sớm	33
---	----

CHƯƠNG 1. GIỚI THIỆU CHUNG

1.1. Bối cảnh và động cơ nghiên cứu

- **Thảm họa thiên nhiên và nhân tạo ngày càng gia tăng**
 - **Tác động lớn đến:**
 - **Con người**
 - **Kinh tế**
 - **Thời gian phục hồi xã hội**
 - **Vai trò của phân tích dữ liệu & học máy trong dự báo và hỗ trợ ra quyết định**
-

1.2. Mục tiêu nghiên cứu


Trong báo cáo này, nhóm/tác giả tập trung giải quyết 3 bài toán dự đoán chính:

- 1. Dự đoán thiệt hại về người**
 - 2. Dự đoán thời gian phục hồi sau thảm họa**
 - 3. Dự đoán mức độ nghiêm trọng của thảm họa**
-

1.3. Phạm vi và dữ liệu sử dụng

- **Nguồn dữ liệu: Global Disaster Response Dataset (2018–2024)**
- **Đối tượng: các sự kiện thảm họa trên phạm vi toàn cầu**
- **Công cụ:**
 - **Python**
 - **Pandas, NumPy**
 - **Scikit-learn**

CHƯƠNG 2. TỔNG QUAN DỮ LIỆU VÀ TIỀN XỬ LÝ



Bộ dữ liệu gồm 50000 mẫu

2.1 Các nhóm đặc trưng chính trong bộ dữ liệu

1. Đặc trưng mức độ thảm họa

Nhóm đặc trưng mức độ thảm họa phản ánh bản chất và mức độ nghiêm trọng của từng sự kiện thảm họa. Các đặc trưng trong nhóm này thường mô tả cường độ, quy mô và loại hình thảm họa, đóng vai trò quan trọng trong việc xác định mức độ ảnh hưởng ban đầu.

Tiêu biểu trong nhóm này là biến `severity_index`, đại diện cho mức độ nghiêm trọng tổng hợp của thảm họa. Ngoài ra, biến `disaster_type` giúp phân loại thảm họa theo từng nhóm như động đất, lũ lụt, bão, cháy rừng,... Qua đó, mô hình có thể học được sự khác biệt về tác động giữa các loại thảm họa khác nhau.

Nhóm đặc trưng này thường có mối liên hệ chặt chẽ với thiệt hại về người và thời gian phục hồi, do các thảm họa có mức độ nghiêm trọng cao thường gây hậu quả nặng nề hơn.

2. Đặc trưng thiệt hại

Nhóm đặc trưng thiệt hại mô tả hậu quả trực tiếp mà thảm họa gây ra đối với con người và kinh tế. Đây là nhóm biến phản ánh rõ nhất mức độ tổn thất thực tế sau khi thảm họa xảy ra.

Các biến tiêu biểu bao gồm `casualties` (số người thương vong) và `economic_loss_usd` (thiệt hại kinh tế). Những đặc trưng này thường có phân bố lệch

và chứa nhiều giá trị ngoại lai, do mức độ thiệt hại giữa các sự kiện thảm họa có sự chênh lệch rất lớn.

Nhóm đặc trưng thiệt hại không chỉ được sử dụng làm biến mục tiêu trong các bài toán dự đoán, mà còn đóng vai trò là biến đầu vào quan trọng cho các mô hình dự đoán thời gian phục hồi và đánh giá mức độ thảm họa.

3. Đặc trưng phản ứng & phục hồi

Nhóm đặc trưng phản ứng và phục hồi phản ánh khả năng ứng phó và khắc phục hậu quả của con người và các tổ chức sau khi thảm họa xảy ra. Đây là nhóm biến mang tính quản lý và can thiệp, ảnh hưởng trực tiếp đến quá trình hồi phục.

Các biến tiêu biểu trong nhóm này bao gồm `response_time_hours` (thời gian phản ứng), `aid_amount_usd` (mức viện trợ), `response_efficiency_score` (hiệu quả phản ứng) và `recovery_days` (số ngày phục hồi). Những đặc trưng này giúp mô hình hiểu được mối quan hệ giữa tốc độ phản ứng, mức hỗ trợ và thời gian phục hồi.

Nhóm đặc trưng này đặc biệt quan trọng trong các bài toán dự đoán thời gian phục hồi, bởi một phản ứng nhanh và hiệu quả thường góp phần rút ngắn đáng kể quá trình khắc phục hậu quả sau thảm họa.

2.2. Mô tả các biến quan trọng

Trong bộ dữ liệu nghiên cứu về thảm họa, một số biến đóng vai trò quan trọng trong việc phân tích và xây dựng các mô hình dự đoán. Các biến này phản ánh mức độ nghiêm trọng của thảm họa, thiệt hại gây ra cũng như khả năng phản ứng và phục hồi sau thảm họa. Cụ thể như sau:

severity_index

Biến `severity_index` biểu thị **mức độ nghiêm trọng tổng hợp của thảm họa**. Đây là chỉ số được xây dựng dựa trên nhiều yếu tố như cường độ thảm họa, phạm vi ảnh

hưởng và mức độ tàn phá. Giá trị của biến này càng cao thì thảm họa càng nghiêm trọng. Biến `severity_index` thường có mối quan hệ chặt chẽ với thiệt hại về người, thiệt hại kinh tế và thời gian phục hồi.

casualties

Biến `casualties` thể hiện **số người thương vong** do thảm họa gây ra. Đây là một trong những chỉ số quan trọng nhất để đánh giá tác động của thảm họa đối với con người. Giá trị của biến này có thể dao động lớn giữa các sự kiện, thường có phân bố lệch và chứa nhiều giá trị ngoại lai. Trong nghiên cứu, `casualties` được sử dụng làm biến mục tiêu trong bài toán dự đoán thiệt hại về người.

economic_loss_usd

Biến `economic_loss_usd` biểu thị **thiệt hại kinh tế ước tính** do thảm họa gây ra, được tính bằng đơn vị đô la Mỹ (USD). Biến này phản ánh mức độ tổn thất về tài sản, cơ sở hạ tầng và hoạt động kinh tế. Tương tự như biến `casualties`, `economic_loss_usd` thường có độ phân tán lớn và được sử dụng trong các bài toán phân tích và dự đoán tác động kinh tế của thảm họa.

response_time_hours

Biến `response_time_hours` thể hiện **thời gian phản ứng** kể từ khi thảm họa xảy ra cho đến khi các hoạt động cứu trợ và hỗ trợ ban đầu được triển khai. Thời gian phản ứng càng ngắn thì khả năng giảm thiểu thiệt hại và rút ngắn thời gian phục hồi càng cao. Do đó, biến này có ảnh hưởng đáng kể đến cả thiệt hại về người và thời gian phục hồi.

aid_amount_usd

Biến aid_amount_usd đại diện cho **tổng giá trị viện trợ** được cung cấp cho khu vực chịu ảnh hưởng của thảm họa, tính bằng USD. Viện trợ bao gồm hỗ trợ tài chính, vật tư, y tế và các nguồn lực khác. Biến này thường được sử dụng để phân tích hiệu quả hỗ trợ và đánh giá tác động của viện trợ đối với quá trình phục hồi sau thảm họa.

recovery_days

Biến recovery_days thể hiện **số ngày cần thiết để khu vực chịu ảnh hưởng phục hồi** sau thảm họa. Đây là biến mục tiêu chính trong bài toán dự đoán thời gian phục hồi. Giá trị của biến này chịu ảnh hưởng bởi mức độ nghiêm trọng của thảm họa, thiệt hại gây ra cũng như hiệu quả phản ứng và hỗ trợ sau thảm họa.

response_efficiency_score

Biến response_efficiency_score phản ánh **mức độ hiệu quả của công tác phản ứng và cứu trợ** sau thảm họa. Chỉ số này được xây dựng dựa trên việc đánh giá tốc độ, chất lượng và mức độ phối hợp của các hoạt động ứng phó. Giá trị càng cao cho thấy phản ứng càng hiệu quả, từ đó góp phần giảm thiểu thiệt hại và rút ngắn thời gian phục hồi.

CHƯƠNG 3. BÀI TOÁN 1 – DỰ ĐOÁN THIẾT HẠI VỀ NGƯỜI

CHƯƠNG 4. BÀI TOÁN 2 – DỰ ĐOÁN THỜI GIAN PHỤC HỒI

4.1. Mô tả bài toán

4.1.1. Loại bài toán

Bài toán dự đoán thời gian phục hồi sau thảm họa được xây dựng dưới dạng bài toán hồi quy (Regression), trong đó mô hình học máy có nhiệm vụ ước lượng một

giá trị số liên tục dựa trên các đặc trưng đầu vào liên quan đến mức độ và phản ứng với thảm họa.

4.1.2. Biến mục tiêu

- Biến mục tiêu (Target): `recovery_days`
- Ý nghĩa: Số ngày cần thiết để khu vực bị ảnh hưởng bởi thảm họa quay trở lại trạng thái ổn định hoặc phục hồi cơ bản.

4.1.3. Ý nghĩa trong quản lý rủi ro thảm họa


Việc dự đoán chính xác thời gian phục hồi mang lại nhiều lợi ích quan trọng:

- Hỗ trợ chính phủ và tổ chức cứu trợ lập kế hoạch phân bổ nguồn lực dài hạn.
- Giúp đánh giá hiệu quả phản ứng khẩn cấp sau thảm họa.
- Là cơ sở để so sánh mức độ tổn thương và khả năng phục hồi giữa các quốc gia, khu vực hoặc loại thảm họa.
- Cung cấp thông tin đầu vào cho các hệ thống cảnh báo và ra quyết định trong quản lý rủi ro thiên tai.

4.2. Phân tích EDA (Exploratory Data Analysis)


Phân tích khám phá dữ liệu được thực hiện nhằm hiểu rõ hơn mối quan hệ giữa biến mục tiêu `recovery_days` và các đặc trưng đầu vào.

4.2.1. Quan hệ giữa *recovery_days* và *severity_index*




- Quan sát cho thấy thời gian phục hồi có xu hướng tăng khi mức độ nghiêm trọng của thảm họa tăng.
- Mọi quan hệ tuyến tính khá tốt
- Đây là feature top đầu để dự đoán thời gian phục hồi sau thảm họa.

4.2.2. Quan hệ giữa *recovery_days* và *response_time_hours*




- Trong dự đoán các sự kiện có thời gian phản ứng càng lâu thường dẫn đến thời gian phục hồi dài hơn, nhưng thực tế ngược lại
- Mối tương quan này cho thấy vai trò quan trọng của phản ứng sớm thường là những thảm họa lớn nên khả năng phục hồi lâu

4.2.3. Quan hệ giữa *recovery_days* và *aid_amount_usd*



- Nhìn chung, các thảm họa nhận được mức viện trợ cao có xu hướng phục hồi lâu hơn, vì viện trợ cao $\Rightarrow$ thảm họa lớn.

4.2.4. Quan hệ giữa *recovery_days* và *disaster_type*



- Một số loại thảm họa như núi lửa phun trào thường có thời gian phục hồi dài hơn so với các loại thiên tai khác

- Điều này phản ánh mức độ phá hủy cơ sở hạ tầng và tác động lâu dài của từng loại thảm họa.

4.2.5. *Quan hệ giữa recovery_days và country*

- Thời gian phục hồi có sự khác biệt rõ rệt giữa các quốc gia.
- Các quốc gia có năng lực kinh tế và hệ thống ứng phó tốt thường phục hồi nhanh hơn.
- Yếu tố quốc gia đóng vai trò gián tiếp thông qua trình độ phát triển, quản lý và cơ sở hạ tầng.

4.3. Mô hình sử dụng

Random Forest Regressor

Trong bài toán này, mô hình Random Forest Regressor được lựa chọn với các lý do sau:

- Khả năng mô hình hóa quan hệ phi tuyến giữa các đặc trưng và biến mục tiêu.
- Ít bị ảnh hưởng bởi nhiễu và outlier so với các mô hình tuyến tính.
- Hoạt động tốt với tập dữ liệu có nhiều đặc trưng khác nhau (số, phân loại đã mã hóa).

Mô hình được huấn luyện trên tập dữ liệu đã qua tiền xử lý, bao gồm:

- Chuẩn hóa hoặc biến đổi log cho một số biến có phân phối lệch.
- Mã hóa các biến phân loại như disaster_type và country.

4.4. Đánh giá mô hình

```
Random Forest Regression results
MAE : 4.10
RMSE : 5.15
R2 : 0.935
```

Mô hình được đánh giá bằng các chỉ số phổ biến trong bài toán hồi quy:

- **MAE (Mean Absolute Error):**

Đo lường sai số tuyệt đối trung bình giữa giá trị dự đoán và giá trị thực tế.

→ Dễ hiểu, phản ánh sai lệch trung bình theo đơn vị ngày.

- **RMSE (Root Mean Squared Error):**

Nhấn mạnh các sai số lớn, phù hợp để đánh giá mức độ ổn định của mô hình.

- **R² (R-squared Score):**

Đo lường mức độ mô hình giải thích được phương sai của biến `recovery_days`.

→ Giá trị R² càng cao cho thấy mô hình càng phù hợp với dữ liệu.

Kết quả đánh giá cho thấy Random Forest Regressor đạt hiệu năng tốt, đặc biệt so với các mô hình tuyến tính trong bối cảnh dữ liệu có nhiều quan hệ phi tuyến.

4.5. Triển khai ứng dụng dự đoán

4.5.1. Mô tả web app Streamlit


Một ứng dụng web đơn giản được xây dựng bằng Streamlit nhằm minh họa khả năng ứng dụng thực tế của mô hình.

4.5.2. Giao diện nhập feature

Disaster Recovery Days Prediction

Nhập các thông tin về thảm họa để dự đoán số ngày hồi phục

Severity Index



Casualties

 - +

Response Time (hours)

 - +

Aid Amount (USD)

 - +

Response Efficiency Score



Predict Recovery Days

Estimated Recovery Days: 55.3 days

Người dùng có thể nhập các thông tin đầu vào như:

- Mức độ nghiêm trọng của thảm họa (severity_index)
- Thời gian phản ứng (response_time_hours)
- Mức viện trợ (aid_amount_usd)
-

4.5.3. Kết quả dự đoán

Estimated Recovery Days: 55.3 days

Sau khi nhấn nút dự đoán, hệ thống sẽ:

- Hiển thị số ngày phục hồi dự đoán
- Giúp người dùng hình dung nhanh mức độ kéo dài của quá trình phục hồi trong từng kịch bản thảm họa.

4.6. Kết luận bài toán 2

4.6.1. Hiệu quả mô hình

- Random Forest Regressor cho thấy khả năng dự đoán tốt trong bối cảnh dữ liệu phức tạp và phi tuyến.
- Mô hình khai thác hiệu quả các đặc trưng liên quan đến mức độ thảm họa và phản ứng cứu trợ.

4.6.2. Tính ứng dụng thực tế

- Kết quả dự đoán có thể hỗ trợ ra quyết định trong quản lý rủi ro thảm họa.
- Mô hình có thể mở rộng để tích hợp vào hệ thống hỗ trợ quyết định, dashboard phân tích hoặc các nền tảng quản lý khủng hoảng trong tương lai.

CHƯƠNG 5. BÀI TOÁN 3 – DỰ ĐOÁN MỨC ĐỘ THẢM HỌA

5.1. GIỚI THIỆU ĐỀ TÀI

5.1.1 Đặt vấn đề

Thiên tai luôn là mối đe dọa lớn đối với sự phát triển kinh tế và an toàn của con người. Việc dự báo sớm không chỉ dừng lại ở việc biết loại thiên tai gì sẽ xảy ra, mà quan trọng hơn là xác định được mức độ nghiêm trọng (Severity) của nó để có phương án ứng phó phù hợp.

5.1.2. Mục tiêu đề án

Xây dựng một quy trình Khoa học dữ liệu (Data Science Pipeline) hoàn chỉnh để:

- Phân tích xu hướng xảy ra thiên tai trên toàn cầu từ năm 2018 đến 2024.
- Xây dựng mô hình Máy học (Machine Learning) dự đoán mức độ nghiêm trọng của thảm họa (Nhỏ, Lớn, Siêu thảm họa) dựa trên các yếu tố đầu vào như vị trí địa lý, thời gian và loại hình thiên tai.

- Tích hợp mô hình vào giao diện tương tác để người dùng dễ dàng tra cứu.

5.2 CƠ SỞ DỮ LIỆU VÀ TIỀN XỬ LÝ

5.2.1. Nguồn dữ liệu

- Tên bộ dữ liệu: `global_disaster_response_2018_2024.csv`
- Mô tả: Bộ dữ liệu bao gồm thông tin chi tiết về các thảm họa xảy ra trên thế giới, bao gồm loại thảm họa, quốc gia, ngày tháng, chỉ số thiệt hại kinh tế, số người thương vong và chỉ số nghiêm trọng.

5.2.2. Quy trình xử lý dữ liệu (*Data Preprocessing*)

Để máy tính có thể hiểu và xử lý, dữ liệu thô đã trải qua các bước làm sạch và chuẩn hóa sau:

1. Việt hóa dữ liệu: Sử dụng từ điển ánh xạ (`vn_disaster_map`) để chuyển đổi tên các loại thảm họa từ tiếng Anh sang tiếng Việt.
 - Ví dụ: Flood -Lũ lụt, Landslide -Sạt lở đất, Earthquake -Động đất.
2. Đổi tên thuộc tính: Các cột dữ liệu được đổi tên để dễ gọi nhớ (ví dụ: `country` Quốc_gia, `severity_index` Chỉ_số_nghiêm_trọng).
3. Xử lý thời gian: Chuyển đổi cột Ngày sang định dạng `datetime` và trích xuất đặc trưng Tháng. Đây là bước quan trọng vì thiên tai thường mang tính mùa vụ (ví dụ: bão thường xảy ra vào các tháng cuối năm).
4. Chuyển đổi biến mục tiêu (Label Engineering):

Bài toán ban đầu là dự đoán chỉ số thiệt hại thực (Hồi quy) được chuyển sang bài toán Phân loại (Classification) để tăng tính ứng dụng. Hàm `classify_disaster` chia mức độ thành 3 lớp:

- Mức 0 (Nhỏ): Những thảm họa có chỉ số nghiêm trọng thấp (`Severity Index < 3`), thiệt hại không đáng kể.
- Mức 1 (Lớn): Những thảm họa gây thiệt hại đáng kể về người và của (`3 ≤ Severity Index < 6`).
- Mức 2 (Siêu thảm họa): Những sự kiện thảm khốc với thiệt hại cực lớn (`Severity Index ≥ 6`).

Chia tập dữ liệu: Dữ liệu sau khi xử lý được chia thành hai tập độc lập:


- Tập huấn luyện (Training set - 80%): Dùng để học các đặc trưng và xây dựng mô hình.
- Tập kiểm thử (Test set - 20%): Dùng để đánh giá độc lập hiệu năng của mô hình trên dữ liệu chưa từng gặp.

5.3 PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)

5.3.1. Phân bố các loại hình thiên tai

Dựa trên thống kê từ bộ dữ liệu, chúng ta có thể thấy tần suất xuất hiện của các loại thiên tai không đồng đều. Việc hiểu rõ phân bố này giúp xác định đâu là những mối đe dọa phổ biến nhất.

- Thống kê số lượng: Các loại thiên tai xảy ra nhiều nhất trong giai đoạn 2018-2024 bao gồm Sạt lở đất (Landslide) với 5,130 vụ, tiếp theo là Động đất (Earthquake) với 5,068 vụ và Lũ lụt (Flood) với 5,039 vụ.



	Quốc_gia	Loại_thảm_họa	# count
8	Australia	Sạt lở đất	281
5	Australia	Nước dâng do bão	269
6	Australia	Nắng nóng cực đoan	269
9	Australia	Động đất	267
3	Australia	Lũ lụt	260
1	Australia	Cháy rừng	259
4	Australia	Lốc xoáy	252
0	Australia	Bão lớn (Hurricane)	240
2	Australia	Hạn hán	240
7	Australia	Phun trào núi lửa	226

30 rows x 3 cols 10 per page << < Page 1 of 3 > >>

```
top1_each_country = top_disaster_by_country.groupby('Quốc_gia').head(1)
top1_each_country.head(10)
```

✓ 0.0s Open 'top1_each_country' in Data Wrangler

	Quốc_gia	Loại_thảm_họa	# count	...
8	Australia	Sạt lở đất	281	
19	Bangladesh	Động đất	279	
23	Brazil	Lũ lụt	281	
33	Canada	Lũ lụt	257	
48	Chile	Sạt lở đất	286	
57	China	Phun trào núi lửa	287	
64	France	Lốc xoáy	267	
75	Germany	Nước dâng do bão	282	
83	Greece	Lũ lụt	275	
98	India	Sạt lở đất	269	


- Trực quan hóa: Biểu đồ tần suất (Bar chart) đã được xây dựng để so sánh số lượng giữa các loại thảm họa, cho thấy sự chênh lệch giữa nhóm thiên tai phổ biến và các nhóm ít gặp hơn như Hạn hán hay Lốc xoáy.

Loại_thảm_họa	# 0	# 1	# 2
Bão lớn (Hurricane)	763	2713	1526
Cháy rừng	734	2679	1541
Hạn hán	794	2698	1404
Lũ lụt	826	2705	1508
Lốc xoáy	733	2597	1609
Nước dâng do bão	756	2700	1532
Nắng nóng cực đoan	799	2646	1556
Phun trào núi lửa	740	2657	1586
Sạt lở đất	806	2718	1606
Động đất	804	2741	1523

5.3.2. Phân tích mức độ nghiêm trọng (Severity Level)

Biên mục tiêu của bài toán là Mức_độ_thảm_họa. Dữ liệu được gán nhãn lại từ chỉ số severity_index (thang đo liên tục) sang 3 mức độ phân loại để phục vụ bài toán cảnh báo:

- Mức 0 (Nguy cơ Nhỏ): severity_index < 3
- Mức 1 (Nguy cơ Lớn): 3 ≤ severity_index < 6
- Mức 2 (Siêu thảm họa): severity_index ≥ 6.




# Mức_độ_thảm_họa	# count
1	26854
2	15391
0	7755

Kết quả thống kê cho thấy sự phân bố dữ liệu giữa các mức độ (ví dụ: Mức 1 chiếm tỷ trọng lớn nhất với 26,854 mẫu, trong khi Mức 0 chỉ có 7,755 mẫu). Điều này đặt ra yêu cầu về việc lựa chọn mét đo đánh giá (metrics) phù hợp như F1-Score thay vì chỉ dùng Accuracy.

5.3.3. Tương quan giữa các đặc trưng Biểu đồ phân tích mức độ ảnh hưởng của các đặc trưng (Feature Importance) từ mô hình Random Forest cho thấy:

- Số ngày phục hồi : Là yếu tố quan trọng nhất để phân loại mức độ nghiêm trọng
- Thời gian phản ứng : Yếu tố quan trọng thứ hai.
- Vị trí địa lý (Vĩ độ/Kinh độ): Có tác động nhất định, phản ánh việc một số khu vực địa lý cụ thể thường xuyên chịu các thảm họa nặng nề hơn (ví dụ: vành đai lửa Thái Bình Dương với động đất/núi lửa).



5.4 XÂY DỰNG VÀ HUẤN LUYỆN MÔ HÌNH

5.4.1. Thiết lập quy trình huấn luyện (Pipeline)

Để đảm bảo tính tự động hóa và nhất quán, quy trình huấn luyện được xây dựng bằng Pipeline của thư viện Scikit-learn, bao gồm 2 bước chính:

1. Tiền xử lý (Preprocessing):

- *Biến số (Numerical)*: Sử dụng StandardScaler để chuẩn hóa dữ liệu về phân phối chuẩn (mean=0, std=1), giúp các thuật toán hội tụ nhanh hơn.

- *Biến phân loại (Categorical)*: Sử dụng OneHotEncoder để mã hóa tên Quốc gia và Loại thảm họa thành các vector số học.
- 2. Mô hình hóa (Modeling): Tích hợp các thuật toán học máy vào cuối đường ống xử lý.

5.4.2. Các thuật toán thử nghiệm

Đồ án đã tiến hành thử nghiệm và so sánh 4 thuật toán mạnh mẽ:

1. Random Forest Classifier: Mô hình học máy tổ hợp (Ensemble) dựa trên cây quyết định, có khả năng chống quá khớp (overfitting) tốt.
2. LightGBM: Thuật toán Boosting tối ưu hóa tốc độ và hiệu năng cao.
3. XGBoost: Một trong những thuật toán Boosting phổ biến nhất hiện nay với khả năng xử lý tốt dữ liệu mất cân bằng.
4. Neural Network (MLP Classifier): Mạng nơ-ron nhân tạo đa tầng để nắm bắt các mối quan hệ phi tuyến phức tạp.

5.4.3. Tối ưu hóa tham số (Hyperparameter Tuning)

Sử dụng kỹ thuật RandomizedSearchCV để tìm kiếm bộ tham số tối ưu cho từng mô hình trên tập huấn luyện. Kết quả tối ưu cho mô hình Random Forest (mô hình tốt nhất) là:

- Số lượng cây (n_estimators): 300
- Độ sâu tối đa (max_depth): 20
- Tiêu chí phân chia: Gini impurity

Bảng tham số tối ưu của các mô hình: Ngoài Random Forest, đồ án cũng đã tìm ra bộ tham số tốt nhất cho các thuật toán khác để đảm bảo sự so sánh công bằng:

- XGBoost: n_estimators=300, learning_rate=0.05, max_depth=8.
- LightGBM: n_estimators=200, learning_rate=0.1, num_leaves=31. Việc tinh chỉnh (tuning) này đảm bảo các mô hình đều hoạt động ở trạng thái tốt nhất trước khi đưa vào so sánh.

5.4.4. Kết quả đánh giá

Kết quả thực nghiệm trên tập kiểm thử (Test set) như sau:


Mô hình	Độ chính xác (Accuracy)	F1-Score (Weighted)
Random Forest	89.31%	0.8928
XGBoost	89.26%	0.8925
LightGBM	89.11%	0.8910
Neural Network	85.96%	0.8597

Nhận xét:

- Mô hình Random Forest đạt kết quả cao nhất cả về độ chính xác và F1-Score.
- XGBoost và LightGBM bám đuổi rất sát với chênh lệch không đáng kể ($< 0.1\%$).
- Mạng nơ-ron (MLP) cho kết quả thấp hơn các mô hình cây trong bài toán dữ liệu dạng bảng này.

Phân tích chi tiết Ma trận nhầm lẫn (Confusion Matrix Analysis): Đi sâu vào phân tích kết quả dự báo trên tập kiểm thử, chúng tôi nhận thấy một số điểm thú vị từ Ma trận nhầm lẫn:

1. Độ chính xác theo lớp: Mô hình nhận diện tốt nhất đối với Mức 1 (Nguy cơ Lớn) – đây là lớp chiếm đa số trong dữ liệu thực tế.
2. Quy luật nhầm lẫn:
 - Sự nhầm lẫn hầu như chỉ xảy ra giữa các mức độ lân cận (ví dụ: dự báo nhầm từ Mức 1 sang Mức 2 hoặc ngược lại).
 - Rất hiếm khi mô hình nhầm lẫn giữa Mức 0 và Mức 2 (Tỷ lệ sai lệch chéo này gần như bằng 0).
 - *Nhận định:* Điều này chứng tỏ mô hình đã học được tính chất "tăng dần" của mức độ nghiêm trọng. Các ca dự báo sai thường rơi vào các trường hợp nằm ở "ranh giới" (ví dụ: chỉ số thiệt hại nằm ngay sát ngưỡng phân chia giữa Mức 1 và Mức 2), nơi mà ngay cả con người cũng khó phân định rạch ròi.



5.5 XÂY DỰNG ỨNG DỤNG DỰ BÁO


Để đưa mô hình vào thực tế, đồ án đã xây dựng một giao diện tương tác trực tiếp trên Jupyter Notebook sử dụng thư viện ipywidgets.

5.5.1. Thiết kế giao diện

Hệ thống bao gồm các thành phần:

- Chọn Quốc gia (Dropdown): Cho phép người dùng chọn quốc gia cần dự báo.
- Chọn Tháng (Slider): Thanh trượt để chọn tháng trong năm (1-12).

- Nút bấm "Xem Dự Báo": Kích hoạt mô hình xử lý.



5.5.2. Chức năng hoạt động

Hàm `du_bao_thien_tai_nang_cap(thang, quoc_gia)` hoạt động theo luồng:

1. Nhận thông tin đầu vào từ người dùng.
2. Tự động điền các thông số phụ (như kinh độ/vĩ độ trung bình của quốc gia đó) để tạo thành vector đầu vào hoàn chỉnh.
3. Đưa qua mô hình đã huấn luyện để dự đoán.
4. Trả về kết quả cảnh báo: "Nguy cơ: Siêu thảm họa", "Nguy cơ: Lớn" hoặc "Nguy cơ: Nhỏ".

Model:	Random Forest	▼
Quốc gia:	Brazil	▼
Thảm họa:	Bão lớn (Hurricane)	▼
Thương vong:	<input type="range"/>	18250
Thiệt hại US...:	<input type="range"/>	1411390000
Phản ứng (g...):	<input type="range"/>	99.00
Viện trợ USD:	<input type="range"/>	822600000
Hiệu quả:	<input type="range"/>	0.70
Phục hồi (n...):	<input type="range"/>	60
Vĩ độ:	<input type="range"/>	10.00
Kinh độ:	<input type="range"/>	105.00
Dự đoán mức độ th...		
Model sử dụng: Random Forest MỨC ĐỘ DỰ ĐOÁN: Siêu thảm họa		

5.5.3 Thống kê số lần thảm họa cùng thời gian đó ở 1 nước của quá khứ

- Nhập Thông tin Quốc Gia
- Nhập tháng dự báo


KẾT QUẢ DỰ BÁO CHO: CHILE - THÁNG 6
 (Dựa trên phân tích 200 sự kiện trong quá khứ)

=====

Lốc xoáy

- Xác suất xảy ra: 13.0%
- Số vụ đã ghi nhận: 26

Sạt lở đất

- Xác suất xảy ra: 11.5%
- Số vụ đã ghi nhận: 23

Nước dâng do bão

- Xác suất xảy ra: 11.0%
- Số vụ đã ghi nhận: 22

5.5.4 KẾT LUẬN

Đồ án đã giải quyết thành công bài toán dự báo mức độ thiên tai thông qua việc áp dụng các kỹ thuật Học máy tiên tiến.

- Ưu điểm: Quy trình xử lý dữ liệu bài bản, trực quan hóa rõ ràng và có sản phẩm ứng dụng thực tế (Widget).
- Hạn chế: Dữ liệu có thể còn phụ thuộc vào các chỉ số lịch sử, cần cập nhật liên tục để tăng độ chính xác theo thời gian thực.
- Hướng phát triển: Tích hợp API thời tiết thực tế để dự báo động (Dynamic Forecasting) thay vì chỉ dựa vào dữ liệu lịch sử.

6.6. TỔNG KẾT & HƯỚNG PHÁT TRIỂN

6.1. Tổng kết kết quả đạt được

Trong phạm vi đề tài, nhóm nghiên cứu đã xây dựng và triển khai thành công ba bài toán dự đoán liên quan đến thảm họa thiên nhiên, bao gồm:

1. Dự đoán thiệt hại kinh tế do thảm họa

- Biến mục tiêu: economic_loss_usd
- Mục tiêu: Ước lượng mức độ tổn thất kinh tế nhằm hỗ trợ phân bổ nguồn lực cứu trợ.

2. Dự đoán thời gian phục hồi sau thảm họa

- Biến mục tiêu: recovery_days
- Mục tiêu: Hỗ trợ lập kế hoạch phục hồi và đánh giá hiệu quả ứng phó.

3. Dự đoán mức độ nghiêm trọng của thảm họa

- Biến mục tiêu: severity_index
- Mục tiêu: Phân loại và đánh giá nhanh mức độ ảnh hưởng của thảm họa.

Các bài toán đều được xây dựng dưới dạng **bài toán hồi quy (Regression)**, áp dụng các mô hình học máy phổ biến và phù hợp với dữ liệu thực tế.

So sánh ưu – nhược điểm của các mô hình sử dụng

- **Linear Regression**

- *Ưu điểm:*
 - Dễ triển khai, dễ giải thích.
 - Phù hợp làm mô hình baseline.
- *Nhược điểm:*
 - Không mô hình hóa được quan hệ phi tuyến.
 - Hiệu năng thấp khi dữ liệu phức tạp.
- **Random Forest Regressor**
 - *Ưu điểm:*
 - Xử lý tốt quan hệ phi tuyến.
 - Ít nhạy cảm với nhiễu và outlier.
 - Hiệu quả cao với dữ liệu đa chiều.
 - *Nhược điểm:*
 - Khó giải thích hơn mô hình tuyến tính.
 - Tốn tài nguyên tính toán hơn.
- **XGBoost Regressor**
 - *Ưu điểm:*
 - Hiệu năng cao khi được tinh chỉnh tốt.
 - Khả năng học các quan hệ phức tạp.
 - *Nhược điểm:*
 - Nhạy cảm với nhiễu.
 - Cần tuning tham số kỹ lưỡng, dễ overfitting với dữ liệu chưa được xử lý tốt.

Nhìn chung, Random Forest Regressor cho kết quả ổn định nhất trong bối cảnh dữ liệu của đề tài, trong khi Linear Regression đóng vai trò mô hình tham chiếu, và XGBoost có tiềm năng cải thiện nếu dữ liệu được mở rộng và làm sạch tốt hơn.

6.2. Hạn chế của nghiên cứu

Mặc dù đạt được các kết quả tích cực, nghiên cứu vẫn tồn tại một số hạn chế:

6.2.1. Dữ liệu còn nhiều

- Dữ liệu thảm họa thu thập từ nhiều nguồn khác nhau nên tồn tại:
 - Giá trị ngoại lai (outliers)
 - Phân phối lệch
 - Sai lệch do báo cáo không đồng nhất giữa các quốc gia
- Điều này ảnh hưởng trực tiếp đến độ chính xác của mô hình.

6.2.2. Thiếu các yếu tố kinh tế – xã hội chuyên sâu

- Bộ dữ liệu hiện tại chưa bao gồm các yếu tố quan trọng như:
 - GDP, thu nhập bình quân đầu người
 - Chỉ số phát triển con người (HDI)
 - Năng lực y tế, cơ sở hạ tầng
- Việc thiếu các biến này làm giảm khả năng phản ánh đầy đủ năng lực phục hồi của từng quốc gia.

6.3. Hướng phát triển

Để nâng cao hiệu quả và tính ứng dụng thực tế của hệ thống, một số hướng phát triển trong tương lai được đề xuất như sau:

6.3.1. Bổ sung dữ liệu thời gian thực

- Tích hợp dữ liệu từ:
 - Hệ thống cảnh báo thiên tai
 - Dữ liệu thời tiết, địa chấn theo thời gian thực
- Giúp mô hình cập nhật liên tục và phản ánh kịp thời tình hình thực tế.

6.3.2. Tích hợp bản đồ và dashboard trực quan

- Kết hợp với các công cụ trực quan như:
 - Bản đồ tương tác (Folium, Plotly)

- Dashboard phân tích (Power BI, Streamlit)
- Hỗ trợ nhà quản lý:
 - Theo dõi khu vực bị ảnh hưởng
 - So sánh mức độ rủi ro theo không gian và thời gian

6.3.3. Ứng dụng trong hệ thống cảnh báo sớm

- Tích hợp mô hình vào hệ thống cảnh báo sớm nhằm:
 - Dự đoán mức độ nghiêm trọng ngay khi thảm họa xảy ra
 - Ước lượng thiệt hại và thời gian phục hồi ban đầu
- Góp phần hỗ trợ ra quyết định nhanh trong các tình huống khẩn cấp